Lab 4 实验报告：图神经网络节点分类

1. 实验目的

本实验从零实现图神经网络的核心组件，并在 Cora 引文网络上进行半监督节点分类。实验关注：

- 图邻接矩阵的构造、归一化和特征传播；
- GCN 与 GraphSAGE 的前向传播、反向传播及梯度验证；
- 训练标签数量有限时，利用整张图进行节点分类；
- 邻接归一化、网络深度和图结构对分类效果的影响；
- 多次图传播对节点特征平滑程度的影响。

2. 数据集与任务

Cora 数据集包含 2,708 篇论文节点，每个节点有 1,433 维词袋特征，标签分为 7 个研究主题。数据加载后对节点特征按行归一化，并将引文关系构造成无向图。

本次运行使用固定随机种子 `0`。训练集包含每类 20 个节点，共 140 个；验证集 500 个节点；测试集 1,000 个节点。其余节点不参与损失或评估，但仍参与整张图上的消息传递，符合传导式半监督学习设置。

3. 模型与实现

3.1 GCN

GCN 每层先通过归一化邻接矩阵聚合邻居表示，再进行线性变换：

```
H_agg  = A_hat @ H
H_next = activation(H_agg @ W + b)
```

默认使用带自环邻接矩阵的对称归一化：

```
A_tilde = A + I
D_tilde[i, i] = sum_j A_tilde[i, j]
A_hat = D_tilde^(-1/2) @ A_tilde @ D_tilde^(-1/2)
```

其中 `D_tilde` 是 `A_tilde` 的度矩阵。默认网络为两层 GCN，第一层后使用 ReLU，输出层产生 7 类分数。

3.2 GraphSAGE

GraphSAGE 将节点自身表示与邻居聚合表示拼接，再映射到下一层：

```
H_agg  = aggregate(A, H)              # mean or element-wise max
H_cat  = concat([H, H_agg], axis=1)
H_next = activation(H_cat @ W + b)
```

实现支持 mean 和 max 聚合。训练损失只对训练掩码中的节点计算；反向传播分别处理自身特征路径和聚合路径。

3.3 训练与验证

模型使用全图批量训练：每个 epoch 在整张图上执行前向和反向传播，以训练掩码中的标签计算交叉熵，并使用 Adam 更新参数。权重衰减施加于权重矩阵。完整测试套件运行结果为 **58 passed**。

4. 实验配置

默认配置如下：

参数	设置
模型	2 层 GCN
隐藏维度	16
邻接归一化	对称归一化，包含自环
优化器	Adam
Epoch	200
学习率	0.01
权重衰减	0.0005
随机种子	0

5. 实验结果与分析

5.1 模型对照实验

以下实验使用相同的数据划分、随机种子和其余默认超参数，每次只改变表中列出的设置：

实验	运行命令	测试损失	测试准确率	训练时间
默认：2 层 GCN、对称归一化、自环	`uv run python train_cora.py`	0.8181	**77.00%**	19.30 s
不归一化邻接	`uv run python train_cora.py --norm none`	1.3838	70.20%	24.50 s
4 层 GCN	`uv run python train_cora.py --num-layers 4`	1.3720	69.20%	42.09 s
恒等邻接（不进行邻居消息传递）	`uv run python train_cora.py --identity-adj`	1.3766	55.70%	26.27 s

默认设置在本次对照中取得最高测试准确率。相较恒等邻接基线，使用图结构后准确率提高 21.30 个百分点；不做邻接归一化时比默认结果低 6.80 个百分点。4 层模型比默认模型低 7.80 个百分点，训练耗时也更长。以上比较只反映当前固定划分和单个随机种子的结果。

5.2 默认模型的分类别结果

默认模型的总体测试损失为 0.8181，测试准确率为 77.00%。各类别测试结果如下：

类别	测试节点数	准确率
Case_Based	96	78.12%
Genetic_Algorithms	157	87.26%
Neural_Networks	321	66.36%
Probabilistic_Methods	151	82.12%
Reinforcement_Learning	81	87.65%
Rule_Learning	69	85.51%
Theory	125	72.80%

模型在 Reinforcement_Learning 和 Genetic_Algorithms 上表现较好，在 Neural_Networks 上准确率最低。类别准确率存在差异，因此仅看总体准确率不足以描述模型对各类节点的识别效果。

5.3 特征平滑实验

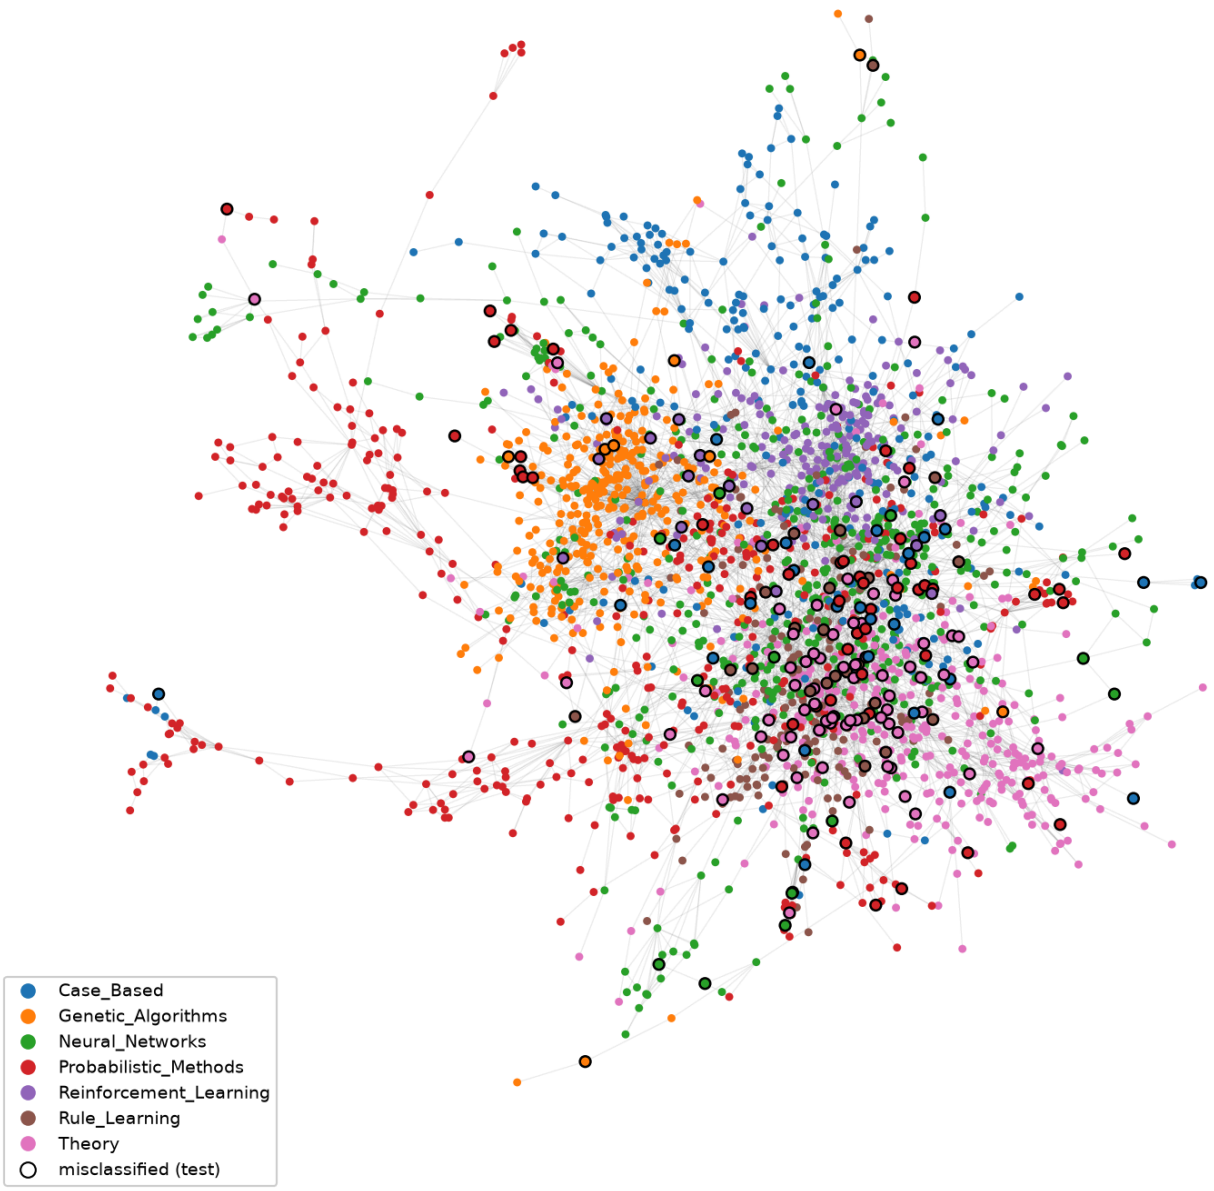
运行 `uv run python train_cora.py --smoothness`，使用默认对称归一化邻接矩阵反复传播输入特征，并在原始图上计算 Dirichlet 能量：

传播步数 k	Dirichlet 能量
0	649.6135
1	139.6819
2	55.9980
3	54.2903
4	43.3412
5	42.0416
6	38.8161
7	37.5394
8	36.0567

随着传播步数增加，Dirichlet 能量整体下降，从 k=0 时的 649.6135 降至 k=8 时的 36.0567。这表示多次传播使相邻节点的特征趋于平滑、节点间差异减小，是过平滑现象的直观表现。

6. 当前输出文件与图可视化

完成默认训练后执行 `uv run python visualize_graph.py`。脚本只绘制 Cora 图的最大连通分量，本次输出统计为 2,485 个节点、5,069 条边。节点颜色表示模型预测类别；测试集中预测错误的节点以黑色边框标记。



最近一次已重新运行默认命令 `uv run python train_cora.py` 和 `uv run python visualize_graph.py`，因此当前下列文件对应默认的 2 层 GCN 配置：

- `outputs/loss_curve.png`：训练集与验证集损失曲线；
- `outputs/accuracy_curve.png`：训练集与验证集准确率曲线；
- `outputs/test_predictions.npz`：测试预测、真实标签、测试掩码和类别；
- `outputs/cora_graph.png`：最大连通分量上的预测类别可视化。

不同实验默认复用同一个 `outputs/` 目录，之后再次运行其他配置会覆盖这些文件。本文表格保留各次运行时记录的对照指标；当前图片和预测文件则是最近一次默认配置运行的产物。

7. 结论与复现

本实验完成了 GCN、GraphSAGE、邻接归一化、反向传播和全图半监督训练流程。在当前 Cora 划分与超参数下，两层、对称归一化的 GCN 达到 77.00% 测试准确率。对照实验显示，图结构消息传递对当前任务有帮助；

未归一化邻接和增加网络深度均未改善测试结果。平滑性实验显示，多次传播会降低节点特征的图 Dirichlet 能量。

复现默认结果及可视化：

```
uv run python train_cora.py
uv run python visualize_graph.py
```

以上结果基于单个随机种子和固定数据划分，不能代表不同划分下的平均表现；进一步比较模型时，应重复多个种子并报告均值与方差。